

Análisis y Técnicas de Machine Learning en la Predicción y Calidad del Café for IEEE Journals

Yonatan Henao
Estudiante (Facultad de Ingeniería)
Universidad de Antioquia
Medellín, Colombia
yonatan.henao@udea.edu.co

Duván Arboleda
Estudiante (Facultad de Ingeniería)
Universidad de Antioquia
Medellín, Colombia
duvan.arboleda1@udea.edu.co

Resumen—En este informe se pretende analizar y evaluar los distintos conjuntos de datos que se han recopilado del Instituto de Calidad del Café (CQI) del año 2018 donde se busca abordar el análisis diseño y simulación contando con las técnicas de aprendizaje de máquina (ML).

Index Terms—Predicción de calidad, análisis de datos, Coffee Quality Institute

I. INTRODUCCIÓN

La calidad del café es un factor determinante en su comercialización, ya que influye directamente en su valor económico y en su posicionamiento dentro del sector. Estas evaluaciones se realizan tradicionalmente mediante procesos de catación, en los cuales expertos analizan atributos sensoriales como el aroma, el sabor y el balance. Aunque este método es el estándar, presenta limitaciones como la subjetividad del criterio humano y la dificultad para escalar el proceso en entornos de alta producción.

Por ello el uso de machine learning surge como una alternativa para apoyar la calificación del café a partir de datos técnicos. Estas herramientas permiten identificar patrones y construir modelos predictivos que facilitan la toma de decisiones en la clasificación. El presente proyecto propone el análisis de una base de datos de *Coffee Quality Institute* (CQI) con el fin de explorar cómo el aprendizaje automático puede ayudar a predecir la calidad de manera más eficiente.

II. DESCRIPCIÓN DEL PROBLEMA

En el mercado caficultor, siempre ha estado ligado a la clasificación y evaluación del café bajo la técnica de catación por el ser humano, dicho proceso puede interpretarse con un matiz de forma subjetiva, costosa y difícil de escalar. Aunque este enfoque es reconocido en la industria, su naturaleza subjetiva puede generar variaciones entre evaluaciones, además de requerir tiempo y recursos. Esto dificulta su aplicación en escenarios donde se necesita rapidez, consistencia y capacidad de análisis sobre grandes cantidades de datos.

Por medio del desarrollo de un sistema de predicción basado en Machine Learning (ML) permite optimizar y estandarizar el proceso de selección. Este enfoque no busca reemplazar

completamente la evaluación tradicional, sino complementarla mediante herramientas de análisis de datos que aporten mayor objetividad a la toma de decisiones.

Para abordar este problema, se empleará la base de datos *Coffee Quality Database*, disponible en Kaggle y construida a partir de información del CQI, recopilada en enero de 2018; que contiene registros relacionados con la calidad del café.

Los conjuntos de datos contienen registros detallados de la clase de café de variedad arábica recolectadas a nivel internacional, en general en el conjunto de datos se registraron unos 1311 registros o muestras de lotes diferentes de éste tipo de café, adicionalmente 43 variables donde indican la ubicación geográfica, métricas de calidad entre otras. De las 43 variables, se destacan algunas numéricas principales: *Aroma*, *Flavor*, *Aftertaste*, *Acidity*, *Body*, *Balance*, *Uniformity*, *Clean Cup*, *Sweetness* y *Cupper Points*. Por otra parte, se encuentran algunas categóricas como: *Altitude*, *Moisture*, *Country of Origin*, *Processing Method* y *Color*.

Una forma de entender la interpretación del conjunto de datos, las variables fueron organizadas en grupos de acuerdo con sus características y dimensión al modelo de aprendizaje automático. En el cuadro I se resumen las principales categorías de variables presentes en el dataset.

Como se observa, el dataset integra variables sensoriales, físicas, de origen y de producción, lo que proporciona una base adecuada para tareas de modelado predictivo.

En algunas partes del dataset, se logran identificar valores nulos ("NA") en las variables: *altitude_low_meters*, *altitude_high_meters* y *altitude_mean_meters* en lugares originarios de Brazil o Tanzania y para variables categóricas como *color* o *Altitude*. Para mitigar estos valores faltantes, se podría utilizar una estrategia de atribución por la mediana en las variables numéricas y la moda para las variables categóricas. De acuerdo a la interpretación del dataset en cuestión, en el paradigma más adecuado es del tipo de aprendizaje supervisado utilizando un modelo de regresión; claramente se puede identificar datos etiquetados o puntajes a lo largo de la historia lo cual da paso para el entrenamiento de algoritmos que modelen la relación de las características del grano y la calidad.

Cuadro I
GRUPOS DE VARIABLES DEL DATASET

Grupo	Variables
Sensoriales	aroma, flavor, aftertaste, acidity, body, balance, uniformity, clean cup, sweetness, cupper points, total cup points
Calidad física	moisture, category one defects, category two defects, quakers, color
Origen	species, country of origin, owner, company, farm name, lot number, mill, producer, region, in-country partner, ICO number
Producción	variety, processing method, harvest year, grading date, number of bags, bag weight
Altitud y certificación	altitude, altitude low meters, altitude high meters, altitude mean meters, unit of measurement, expiration, certification body, certification address, certification contact

III. ESTADO DEL ARTE

Previamente bajo la investigación de varios artículos relacionados con la clasificación de la calidad del café en varios países productores de este grano en la respectiva caracterización, se observaron diferentes paradigmas de aprendizaje las cuales se destacan:

- El aprendizaje no supervisado en los artículos: **“On characterization of sensory data in presence of missing values: The case of sensory coffee quality assessment”**[1] y **“Analysis of Sensory Attributes that Influence the Perception of Coffee Quality through Multivariate Technique Main Components”**[2].
- Por otra parte el aprendizaje supervisado para los artículos: **“Utilizing Machine Learning Techniques for Excellent Coffee Prediction”**[3] y **“Modelo de aprendizaje automático para la predicción de la calidad del café”**[4].

Es importante destacar las diferencias entre las técnicas de aprendizaje utilizadas para el desarrollo de cada uno de los problemas planteados en los artículos dado el objeto de estudio para analizar varias características del grano como la dulzura, sabor, amargura, fragancia, etc.. Mientras Ochoa-Muñoz[1] y Espinoza Romano [2] buscan caracterizar relaciones entre atributos sensoriales mediante técnicas multivariadas, los otros autores Melewwé Thantrige [3] y Suárez Peña [4] entrenan modelos supervisados para estimar y clasificar la calidad del café.

III-A. Técnicas no supervisados

III-A1. Análisis Factorial Múltiple: Una de las técnicas que ha sido ampliamente objeto de estudio de la estadística multivariada, además de analizar variables que pueden ser agrupadas por tipo o el interés deseado propuesto en [1], es el Análisis Factorial Múltiple (MFA). Esta técnica permite analizar simultáneamente grupos de variables cuantitativas y cualitativas, con el fin buscar un equilibrio de cada grupo antes de aplicar una reducción de dimensión. El artículo señala que el MFA se desarrolla en tres etapas principales: primero,

se realizan análisis parciales sobre cada grupo de variables; luego, se pondera cada grupo para equilibrar su influencia; finalmente, se aplica un PCA global sobre la tabla ponderada. El MFA en general se expresa de la siguiente forma, se tienen grupos K de variables:

$$X = [X^1 | X^2 | \dots | X^K]$$

donde cada X^k es una matriz de datos (mismas n observaciones, distintas variables). La normalización por grupo se realiza mediante:

$$\tilde{X}^k = \frac{1}{\sqrt{\lambda_1^k}} X^k$$

seguido, la matriz total o ponderada se construye como:

$$\tilde{X} = [\tilde{X}^1 | \tilde{X}^2 | \dots | \tilde{X}^K]$$

Adicionalmente se aplica una descomposición PCA (Análisis de Componentes Principales):

$$\tilde{X} = U\Delta V^T$$

o de forma equivalente:

$$\tilde{X}^T \tilde{X} v = \lambda v$$

donde v , λ y $U\Delta$ representan:

- v : vectores propios (direcciones principales).
- λ : valores propios.
- $U\Delta$: coordenadas de los individuos.

Los factores globales se pueden obtener:

$$F = \tilde{X}V$$

por tanto, el MFA buscar maximizar la varianza en su totalidad teniendo en cuenta que los grupos se hayan equilibrado con anterioridad:

$$\max_j v^T \tilde{X}^T \tilde{X} v, ||v|| = 1$$

En resumen, se llega a que MFA:

$$MFA \approx PCA\left(\frac{X^1}{\sqrt{\lambda_1^1}}, \dots, \frac{X^K}{\sqrt{\lambda_1^K}}\right)$$

Hay que mencionar que los autores [1] indican que MFA pueden ser robusto ante la presencia de datos faltantes, sin embargo el alto porcentaje de sustitución de valores pueden generar una sobreestimación de la relación entre variables y afectar la interpretación de los factores. Por esta razón, el uso del MFA en datos sensoriales exige una revisión minuciosa de la calidad de la información y del método de sustitución empleado.

III-A2. Análisis de Componentes Principales: En la investigación[2], el modelo utilizado fue el Análisis de Componentes Principales (ACP), aplicado sobre variables sensoriales. Esta técnica permitió reducir la dimensionalidad del conjunto de datos y representar la mayor parte de la información en un número menor de componentes principales. De forma general, cada componente principal se expresa como:

$$y_j = a_{j1}x_1 + a_{j2}x_2 + \dots + a_{jp}x_p = a'_j x$$

Para conservar la escala y garantizar la ortogonalidad, se impone la restricción:

$$a'_j a_j = \sum_{k=1}^p a_{kj}^2 = 1$$

El cálculo de los componentes se relaciona con los valores y vectores propios de la matriz de correlaciones o de varianzas-covarianzas, mediante:

$$(\Sigma - \lambda I)a_1 = 0$$

y el polinomio característico:

$$|\Sigma - \lambda I| = 0$$

Además, la proporción de varianza explicada por cada componente se calcula como:

$$\frac{\lambda_i}{\sum_{j=1}^p \lambda_j}$$

III-B. Modelos supervisados

III-B1. Modelos de regresión: Por otra parte, otra de las técnicas empleadas para el análisis de atributos en la predicción de la calidad del café, con el análisis más robusto en cuanto a este tipo de aprendizaje es utilizado en la investigación de [3] que selecciona 18 atributos relevantes para el análisis, incluyendo variables sensoriales junto con variables no sensoriales como especies, variety y country of origin. Para ello, el autor empleó cuatro modelos: **Random Forest (RF)**, **Gradient Boosting Machine (GBM)**, **Support Vector Regression** y un modelo híbrido basado en las predicciones de los tres modelos anteriores, además complementa con validación cruzada **K-Fold** con optimización de hiperparámetros para ajustar estos modelos.

Entre los modelos implementados es GBM siendo una técnica que desarrolla un modelo predictivo de un conjunto muy común en árboles de decisión, GBM minimiza los errores ajustando los nuevos modelos a los errores residuales del conjunto actual. Este modelo se conoce por su precisión predictiva, su flexibilidad frente a múltiples conjuntos de datos siendo capaz de manejar eficientemente tareas de regresión o de clasificación. En el artículo indica que se emplearon 100 árboles dentro del ensamble, para aumentar la capacidad del modelo y se fijó un estado aleatorio para garantizar la reproducibilidad de los resultados.

Para GBM, sea un conjunto de datos:

$$\{(x_i, y_i)\}_{i=1}^n$$

Queremos encontrar una función $F(x)$ que minimice una función de pérdida $L(y, F(x))$. El modelo comienza con una constante:

$$F_0(x) = \arg \min_{\gamma} \sum_{i=1}^n L(y_i, \gamma)$$

En cada iteración m (para $m = 1, \dots, M$), se calcula el gradiente negativo, que representa la dirección en la que debemos ajustar el modelo (descenso por gradiente en el espacio funcional).

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{m-1}}$$

En el ajuste del modelo base, se entrena un modelo débil $h_m(x)$ para aproximar los residuos:

$$h_m(x) \approx r_{im}$$

Después se calcula el paso óptimo

$$\gamma_m = \arg \min_{\gamma} \sum_{i=1}^n L(y_i, F_{m-1}(x_i) + \gamma h_m(x_i))$$

y se actualiza el modelo

$$F_m(x) = F_{m-1}(x) + \nu \gamma_m h_m(x)$$

donde ν es la tasa de aprendizaje. (learning rate).

Modelo final:

$$F_M(x) = F_0(x) + \sum_{m=1}^M \nu \gamma_m h_m(x)$$

La validación del trabajo de Melewwé [3] se realizó mediante una separación del conjunto de datos en entrenamiento y prueba. El desempeño se evaluó mediante RMSE, MAE y R^2 , definidos como:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

El RMSE penaliza con mayor fuerza los errores grandes, el MAE mide el error absoluto promedio y R^2 indica la proporción de variabilidad de la variable objetivo explicada por el modelo.

Y ya por último, tenemos el trabajo de Suárez Peña [4], donde a diferencia de otros estudios centrados en variables sensoriales, esta investigación incorpora variables físicas y visuales del grano, tales como humedad, altitud, color, etc. Hay que mencionar que este trabajo no usa la base CQI para modelar, sino una base construida con apoyo de Almacafé.

El autor aborda el problema desde dos enfoques: clasificación y regresión. En el enfoque de clasificación, se empleó modelos como **Árbol de Decisión**, **K-Nearest Neighbors (KNN)** y una **Red Neuronal** para separar las muestras en categorías de alta y baja calidad. En el enfoque de regresión, se utilizó modelos como **Support Vector Regression (SVR)**, **redes neuronales de regresión** y **redes neuronales de regresión múltiple**. En esta última técnica se implementó para encontrar la función matemática que mejor ajusta a la relación de las características físicas y/o sensoriales y el puntaje final.

Uno de los modelos matemáticos considerados fue Support Vector Regression, cuya forma general busca minimizar el error manteniendo una función lo más plana posible:

$$\min_{w,b,\xi,\xi^*} \frac{1}{2} w^T w + C \sum_{i=1}^l \xi_i + C \sum_{i=1}^l \xi_i^*$$

sueto a:

$$w^T \Phi(x_i) + b - z_i \leq \epsilon + \xi_i$$

$$z_i - w^T \Phi(x_i) - b \leq \epsilon + \xi_i^*$$

$$\xi_i, \xi_i^* \geq 0$$

donde x_i es las variables de entrada del café verde, z_i al valor real de calidad, C penalización del error y ϵ el margen de tolerancia del modelo. Para la validación del modelo esta expresada como:

$$CV(k) = \frac{1}{k} \sum_{i=1}^k MSE_i$$

III-C. Comparación de resultados de los estudios revisados

Los resultados obtenidos de la investigación[1], destacan entre la coherencia que, en cuanto evidenciaron los valores faltantes, se imputaron utilizando MFA; Los resultados son los esperados para el análisis multivariado a razón del crecimiento del porcentaje de datos "NA", la inercia de todos los datos, demuestra la importancia de los componentes a lo largo aumenta paulatinamente. En la práctica, puede ser razonable porque El método de imputación utiliza la información disponible y realiza funciones según otros registros en el conjunto de datos. Sin embargo, los analistas a menudo obtuvieron resultados más bajos inercia cuando los individuos han variado poco.




Figura 1. Trazado de porcentaje de inercia

La figura 1. muestra el trazado del porcentaje de inercia alcanzado por MFA con la imputación de datos y valores faltantes. A pesar de la baja relevancia de los escenarios con un porcentaje superior al 50 %, el gráfico presenta la tendencia de inercia acumulativa basada en la proporción de valores faltantes.

En la investigación [2], los resultados obtenidos de los atributos sensoriales más importantes, es el sabor, seguido del aroma y gusto, dado que es la preferencia de los consumidores finales. Partiendo de lo anterior, se puede caracterizar, segmentar y describir a los países que sean:

- Países cercanos que tienen perfiles similares.
- Países alejados que son diferentes entre sí.
- La dirección que indica relaciones con las variables originales.




Figura 2. Granjas por países según los atributos sensoriales de café en el plano de componentes principales.

El resultado en la figura 2, en la parte derecha, Colombia en una de sus fincas posee altas puntuaciones en las variables, reflejando una percepción positiva en Aroma, Sabor, Regusto, Acidez, Cuerpo, Balance y puntuación General. A diferencia de Etiopía en la parte superior que muestra una percepción media en la mayoría de los atributos sensoriales y el Salvador ubicado en la parte izquierda superior que tiene una puntuación relativamente baja en una de sus fincas. En la parte central, el conjunto mayoritario de las fincas posee altas puntuaciones en las variables reflejando una percepción positiva en Aroma, Sabor, Regusto, Acidez, Cuerpo, Balance y Puntuación General.

Cuadro II
EVALUACIÓN DE MODELOS

Model Name	RMSE		MAE		R Squared	
	Training Set	Testing Set	Training Set	Testing Set	Training Set	Testing Set
Random Forest	0.3357	4.0333	0.1589	0.6594	0.9845	0.4892
GBM	0.3793	3.6760	0.2381	0.6186	0.9803	0.5757
SVR	0.7455	0.7803	0.2780	0.3459	0.9239	0.9808
Hybrid Model	0.4264	2.5915	0.1986	0.4805	0.9751	0.7891

Los resultados analizados de [3], se puede expresar como se muestra en el cuadro II, donde se visualiza una comparación

de los cuatro modelos empleados y los resultados en el Error Cuadrático Medio (RMSE), Error Medio Absoluto (MAE) y R cuadrado, se evidencia que en el uso de Support Vector Regression (SVR) supera a: Random Forest, GBM e inclusive al modelo híbrido que al ser consistente tanto en conjuntos de datos de entrenamiento como a los de prueba, obtuvo de 0,7455 y 0,7803 en el resultado del RMSE para los datos de entrenamiento y de prueba respectivamente demostrando que SVR logró generalizar a los datos de prueba o los no vistos. Asimismo, 0,2780 y los datos de entrenamiento y pruebas confirman su capacidad de predicción La calidad del café obtiene puntuaciones precisas. El modelo híbrido muestra el segundo mejor rendimiento en las predicciones al adquirir 2,5915(RMSE), 0,4805(MAE) y 0,7891(R al cuadrado) mientras que GBM y Random Forest obtuvieron la tercera y cuarta posición en la predicción del valor de la calidad del café.

	Aroma	Sabor	Sabor.Residual	Acidez	Cuerpo	Balance	Uniformidad	Taza.Limpia	Dulzor	Overall
0	4.169149	4.081212	3.904573	4.129179	3.863088	3.958924	4.205576	3.759331	4.053699	3.738016
1	4.186828	4.102150	3.927104	4.148110	3.883823	3.983422	4.228165	3.781557	4.075748	3.761476
2	4.153579	4.062771	3.884729	4.112505	3.844825	3.937347	4.185680	3.739755	4.034280	3.717353
3	4.166920	4.078571	3.901731	4.126791	3.860473	3.955834	4.202726	3.756527	4.050918	3.735056
4	4.092703	3.990672	3.807145	4.047317	3.773424	3.852988	4.107894	3.663220	3.958355	3.636569
5	4.077327	3.972460	3.787548	4.030851	3.755389	3.831680	4.088247	3.643888	3.939178	3.616164
6	4.157124	4.066969	3.889247	4.116301	3.848983	3.942259	4.190209	3.744212	4.038701	3.722057
7	4.253943	4.181639	4.012641	4.219980	3.962543	4.076427	4.313923	3.865937	4.159454	3.850540
8	4.227818	4.150697	3.979344	4.192003	3.931900	4.040223	4.280540	3.833091	4.126870	3.815870
9	4.124254	4.028039	3.847355	4.081102	3.810430	3.896709	4.148209	3.702887	3.997705	3.678437
10	4.116493	4.018847	3.837464	4.072792	3.801327	3.885954	4.138292	3.693129	3.988026	3.668138
11	4.249141	4.175951	4.006520	4.214838	3.956910	4.069772	4.307787	3.859900	4.153465	3.844167

Figura 3. Resultados de las predicciones del modelo de regresión múltiple.

Uno de los resultados obtenidos donde el problema se enfoca en la regresión múltiple, es decir, lograr predecir los 10 atributos de calidad, a partir de los datos de entrada de la tesis[4]. Para ello se dejan 10 nodos en la capa de salida, uno por cada caracterizador de calidad. Una se completa el entrenamiento, los resultados de la figura 3 , el MAE llega al valor de 12.55 % y una desviación del 5.1 %. Se aprecia generalmente la inclinación en la red trata de generalizar los resultados hacia la media de ellos, en los datos individuales se pueden apreciar diferencias tanto en las variables de una misma muestra, como en las muestras en general.

IV. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

V. REDUCCIÓN DE DIMENSIÓN

REFERENCIAS

- [1] A. F. Ochoa-Muñoz, J. A. Peña-Torres, C. E. García-Bermúdez, K. F. Mosquera-Muñoz y J. Mesa-Díez, "On characterization of sensory data in presence of missing values: The case of sensory coffee quality assessment", *Ingeniare. Revista chilena de ingeniería*, vol. 30, no. 3, pp. 564–573, 2022. [En línea]. Disponible en: https://revistas.uta.cl/pdf/2940/vol30_n3_art12.pdf
- [2] V. Espinoza Romano, V. R. Figueroa Camacho y S. A. Aldunate Flores, "Análisis de atributos sensoriales que influyen en la percepción de calidad del café mediante la técnica multivariada de componentes principales," *Acta Nova*, vol. 11, no. 4, Cochabamba, Bolivia, Nov. 2024. [En línea]. Disponible en: <http://www.scielo.org.bo/pdf/ran/v11n4/1683-0789-ran-11-04-353.pdf>

- [3] M. K. Melewwe Thantrige, "Utilizing Machine Learning Techniques for Excellent Coffee Prediction," Tesis de maestría, MSc Research Project, School of Computing, National College of Ireland, 2024. [En línea]. Disponible en: <https://norma.ncirl.ie/id/eprint/7570>
- [4] J. A. Suárez Peña, "Modelo de aprendizaje automático para la predicción de la calidad del café," Tesis de maestría, Universidad Distrital Francisco José de Caldas, Bogotá, Colombia, 2024. [En línea]. Disponible en: <http://hdl.handle.net/11349/23560>