

Análisis y Técnicas de Machine Learning en la Predicción y Calidad del Café

Yonatan Henao
Estudiante (Facultad de Ingeniería)
Universidad de Antioquia
Medellín, Colombia
yonatan.henao@udea.edu.co

Duván Arboleda
Estudiante (Facultad de Ingeniería)
Universidad de Antioquia
Medellín, Colombia
duvan.arboleda1@udea.edu.co

Resumen—En este informe se pretende analizar y evaluar los distintos conjuntos de datos que se han recopilado del Instituto de Calidad del Café (CQI) del año 2018 donde se busca abordar el análisis diseño y simulación contando con las técnicas de aprendizaje de máquina (ML).

Index Terms—Predicción de calidad, análisis de datos, Coffee Quality Institute

I. INTRODUCCIÓN

La calidad del café es un factor determinante en su comercialización, ya que influye directamente en su valor económico y en su posicionamiento dentro del sector. Estas evaluaciones se realizan tradicionalmente mediante procesos de catación, en los cuales expertos analizan atributos sensoriales como el aroma, el sabor y el balance. Aunque este método es el estándar, presenta limitaciones como la subjetividad del criterio humano y la dificultad para escalar el proceso en entornos de alta producción.

Por ello el uso de machine learning surge como una alternativa para apoyar la calificación del café a partir de datos técnicos. Estas herramientas permiten identificar patrones y construir modelos predictivos que facilitan la toma de decisiones en la clasificación. El presente proyecto propone el análisis de una base de datos *Coffee Quality Institute* (CQI) con el fin de explorar cómo el aprendizaje automático puede ayudar a predecir la calidad de manera más eficiente.

II. DESCRIPCIÓN DEL PROBLEMA

El mercado caficultor, siempre ha estado ligado a la clasificación y evaluación del café bajo la técnica de catación por el ser humano, dicho proceso puede interpretarse con un matiz de forma subjetiva, costosa y difícil de escalar. Aunque este enfoque es reconocido en la industria, su naturaleza subjetiva puede generar variaciones entre evaluaciones, además de requerir tiempo y recursos. Esto dificulta su aplicación en escenarios donde se necesita rapidez, consistencia y capacidad de análisis sobre grandes cantidades de datos.

Por medio del desarrollo de un sistema de predicción basado en Machine Learning (ML) permite optimizar y estandarizar el proceso de selección. Este enfoque no busca reemplazar completamente la evaluación tradicional, sino complementarla mediante herramientas de análisis de datos que aporten mayor objetividad a la toma de decisiones.

Para abordar este problema, se empleará la base de datos *Coffee Quality Database*, disponible en Kaggle y construida a partir de información del CQI, recopilada en enero de 2018; que contiene registros relacionados con la calidad del café.

Los conjuntos de datos contienen registros detallados de la clase de café de variedad arábica recolectadas a nivel internacional. En general en el conjunto de datos se registraron unos 1311 registros o muestras de lotes diferentes de éste tipo de café, adicionalmente 43 variables donde indican la ubicación geográfica, métricas de calidad entre otras. De las 43 variables, se destacan algunas numéricas principales: *Aroma*, *Flavor*, *Aftertaste*, *Acidity*, *Body*, *Balance*, *Uniformity*, *Clean Cup*, *Sweetness* y *Cupper Points*. Por otra parte, se encuentran algunas categóricas como: *Altitude*, *Moisture*, *Country of Origin*, *Processing Method* y *Color*.

Una forma de entender la interpretación del conjunto de datos, las variables fueron organizadas en grupos de acuerdo con sus características. En el cuadro I se resumen las principales categorías de variables presentes en el dataset.

Cuadro I
GRUPOS DE VARIABLES DEL DATASET

Grupo	Variables
Sensoriales	aroma, flavor, aftertaste, acidity, body, balance, uniformity, clean cup, sweetness, cupper points, total cup points
Calidad física	moisture, category one defects, category two defects, quakers, color
Origen	species, country of origin, owner, company, farm name, lot number, mill, producer, region, in-country partner, ICO number
Producción	variety, processing method, harvest year, grading date, number of bags, bag weight
Altitud y certificación	altitude, altitude low meters, altitude high meters, altitude mean meters, unit of measurement, expiration, certification body, certification address, certification contact

Como se observa, el dataset integra variables sensoriales, físicas, de origen y de producción, lo que proporciona una base adecuada para tareas de modelado predictivo.

En algunas partes del dataset, se logran identificar valores nulos ("NA") en las variables: *altitude_low_meters*, *altitude_high_meters* y *altitude_mean_meters* en lugares originarios

de Brazil o Tanzania y para variables categóricas como *color* o *Altitude*. Para mitigar estos valores faltantes, se podría utilizar una estrategia de atribución por la mediana en las variables numéricas y la moda para las variables categóricas. De acuerdo a la interpretación del dataset en cuestión, en el paradigma más adecuado es del tipo de aprendizaje supervisado utilizando un modelo de regresión; claramente se puede identificar datos etiquetados o puntajes a lo largo de la historia lo cual da paso para el entrenamiento de algoritmos que modelen la relación de las características del grano y la calidad.

III. ESTADO DEL ARTE

Previamente bajo la investigación de varios artículos relacionados con la evaluación de la calidad del café en varios países productores de este grano en la respectiva caracterización, se observaron diferentes paradigmas de aprendizaje las cuales se destacan:

- El aprendizaje no supervisado en los artículos: **“On characterization of sensory data in presence of missing values: The case of sensory coffee quality assessment”**[1] y **“Analysis of Sensory Attributes that Influence the Perception of Coffee Quality through Multivariate Technique Main Components”**[2].
- Por otra parte el aprendizaje supervisado para los artículos: **“Utilizing Machine Learning Techniques for Excellent Coffee Prediction”**[3] y **“Modelo de aprendizaje automático para la predicción de la calidad del café”**[4].

Es importante destacar las diferencias entre las técnicas de aprendizaje utilizadas para el desarrollo de cada uno de los problemas planteados en los artículos dado el objeto de estudio para analizar varias características del grano como la dulzura, sabor, amargura, fragancia, etc.. Mientras Ochoa-Muñoz[1] y Espinoza Romano [2] buscan caracterizar relaciones entre atributos sensoriales mediante técnicas multivariadas, los otros autores Melewwé Thantrige [3] y Suárez Peña [4] entrenan modelos supervisados para estimar la calidad del café.

III-A. Técnicas no supervisados

III-A1. Análisis Factorial Múltiple: Una de las técnicas que ha sido ampliamente objeto de estudio de la estadística multivariada, además de analizar variables que pueden ser agrupadas por tipo o el interés deseado propuesto en [1], es el Análisis Factorial Múltiple (MFA). Esta técnica permite analizar simultáneamente grupos de variables cuantitativas y cualitativas, con el fin buscar un equilibrio de cada grupo antes de aplicar una reducción de dimensión. El artículo señala que el MFA se desarrolla en tres etapas principales: primero, se realizan análisis parciales sobre cada grupo de variables; luego, se pondera cada grupo para equilibrar su influencia; finalmente, se aplica un PCA global sobre la tabla ponderada. El MFA en general se expresa de la siguiente forma, se tienen grupos K de variables:

$$X = [X^1 | X^2 | \dots | X^K]$$

donde cada X^k es una matriz de datos (mismas n observaciones, distintas variables). La normalización por grupo se realiza mediante:

$$\tilde{X}^k = \frac{1}{\sqrt{\lambda_1^k}} X^k$$

seguido, la matriz total o ponderada se construye como:

$$\tilde{X} = [\tilde{X}^1 | \tilde{X}^2 | \dots | \tilde{X}^K]$$

Adicionalmente se aplica una descomposición PCA (Análisis de Componentes Principales):

$$\tilde{X} = U\Delta V^T$$

o de forma equivalente:

$$\tilde{X}^T \tilde{X} v = \lambda v$$

donde v , λ , k , λ_1^k y $U\Delta$ representan:

- v : vectores propios (direcciones principales).
- λ : valores propios.
- k : indicador del grupo.
- λ_1^k : varianza máxima local.
- $U\Delta$: coordenadas de los individuos.

Los factores globales se pueden obtener:

$$F = \tilde{X}V$$

por tanto, el MFA buscar maximizar la varianza en su totalidad teniendo en cuenta que los grupos se hayan equilibrado con anterioridad:

$$\max_j v^T \tilde{X}^T \tilde{X} v, ||v|| = 1$$

En resumen, se llega a que MFA:

$$MFA \approx PCA\left(\frac{X^1}{\sqrt{\lambda_1^1}}, \dots, \frac{X^K}{\sqrt{\lambda_1^K}}\right)$$

Hay que mencionar que los autores [1] indican que MFA pueden ser robusto ante la presencia de datos faltantes, sin embargo el alto porcentaje de sustitución de valores pueden generar una sobreestimación de la relación entre variables y afectar la interpretación de los factores. Por esta razón, el uso del MFA en datos sensoriales exige una revisión minuciosa de la calidad de la información y del método de sustitución empleado.

III-A2. Análisis de Componentes Principales: En la investigación[2], el modelo utilizado fue el Análisis de Componentes Principales (ACP), aplicado sobre variables sensoriales. Esta técnica permitió reducir la dimensionalidad del conjunto de datos y representar la mayor parte de la información en un número menor de componentes principales. De forma general, cada componente principal se expresa como:

$$y_j = a_{j1}x_1 + a_{j2}x_2 + \dots + a_{jp}x_p = a'_j x$$

Para conservar la escala y garantizar la ortogonalidad, se impone la restricción:

$$a'_j a_j = \sum_{k=1}^p a_{kj}^2 = 1$$

El cálculo de los componentes se relaciona con los valores y vectores propios de la matriz de correlaciones o de varianzas-covarianzas, mediante:

$$(\Sigma - \lambda I)a_1 = 0$$

y el polinomio característico:

$$|\Sigma - \lambda I| = 0$$

Además, la proporción de varianza explicada por cada componente se calcula como:

$$\frac{\lambda_i}{\sum_{j=1}^p \lambda_j}$$

III-B. Modelos supervisados

III-B1. Modelos de regresión: Por otra parte, otra de las técnicas empleadas para el análisis de atributos en la predicción de la calidad del café [3], la selección de los atributos más relevantes para el análisis, incluyendo variables sensoriales y a la par de las variables no sensoriales denominadas: species, variety y country of origin. Para ello, el autor empleó cuatro modelos: **Random Forest (RF)**, **Gradient Boosting Machine (GBM)**, **Support Vector Regression** y un modelo híbrido basado en las predicciones de los tres modelos anteriores, además complementa con validación cruzada **K-Fold** con optimización de hiperparámetros para ajustar estos modelos.

Entre los modelos implementados es GBM siendo una técnica que desarrolla un modelo predictivo de un conjunto muy común en árboles de decisión, GBM minimiza los errores ajustando los nuevos modelos a los errores residuales del conjunto actual. Este modelo se conoce por su precisión predictiva, su flexibilidad frente a múltiples conjuntos de datos siendo capaz de manejar eficientemente tareas de regresión o de clasificación. En el artículo menciona el uso de 100 árboles dentro del ensamble, para aumentar la capacidad del modelo y fijando un estado aleatorio o semilla garantizando la reproducibilidad de los resultados.

Para GBM, sea un conjunto de datos:

$$\{(x_i, y_i)\}_{i=1}^n$$

Queremos encontrar una función $F(x)$ que minimice una función de pérdida $L(y, F(x))$. El modelo comienza con una constante y en cada iteración m (para $m = 1, \dots, M$), se calcula el gradiente negativo, que representa la dirección en la que debemos ajustar el modelo (descenso por gradiente en el espacio funcional).

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{m-1}}$$

En el ajuste del modelo base, se entrena un modelo débil $h_m(x)$ para aproximar los residuos:

$$h_m(x) \approx r_{im}$$

Después se calcula el paso óptimo

$$\gamma_m = \arg \min_{\gamma} \sum_{i=1}^n L(y_i, F_{m-1}(x_i) + \gamma h_m(x_i))$$

y se actualiza el modelo

$$F_m(x) = F_{m-1}(x) + \nu \gamma_m h_m(x)$$

donde ν es la tasa de aprendizaje. (learning rate).

Modelo final:

$$F_M(x) = F_0(x) + \sum_{m=1}^M \nu \gamma_m h_m(x)$$

Por último, a diferencia de otros estudios centrados en variables sensoriales, la investigación [4] incorpora variables físicas y visuales del grano, tales como humedad, altitud, color, etc. Hay que mencionar que este trabajo no usa la base CQI para modelar, sino una base construida con apoyo de Almacafé.

El autor aborda el problema desde dos enfoques: clasificación y regresión. En el enfoque de clasificación, se emplean modelos como **Árbol de Decisión**, **K-Nearest Neighbors (KNN)** y una **Red Neuronal** para separar las muestras en categorías de alta y baja calidad. En el enfoque de regresión, se utilizan modelos como **Support Vector Regression (SVR)**, **redes neuronales de regresión** y **redes neuronales de regresión múltiple**. En esta última técnica se implementó para encontrar la función matemática que mejor ajusta a la relación de las características físicas y/o sensoriales y el puntaje final.

III-C. Comparación de resultados de los estudios revisados

Los resultados obtenidos de la investigación [1], destacan entre la coherencia que, en cuanto evidenciaron los valores faltantes, se imputaron utilizando MFA; Los resultados son los esperados para el análisis multivariado a razón del crecimiento del porcentaje de datos "NA", la inercia de todos los datos, demuestra la importancia de los componentes a lo largo aumenta paulatinamente. En la práctica, puede ser razonable porque El método de imputación utiliza la información disponible y realiza funciones según otros registros en el conjunto de datos. Sin embargo, los analistas a menudo obtuvieron resultados más bajos inercia cuando los individuos han variado poco.

En la investigación [2], los resultados obtenidos reflejan que el sabor es el atributo sensorial más importante, seguido del aroma y el gusto, lo cual se alinea con las preferencias de los consumidores finales. Partiendo de lo anterior, se puede caracterizar, segmentar y describir a los países que sean:

- Países cercanos que tienen perfiles similares.
- Países alejados que son diferentes entre sí.
- La dirección que indica relaciones con las variables originales.




Figura 1. Granjas por países según los atributos sensoriales de café en el plano de componentes principales.

El resultado en la figura 1, en la parte derecha casi a la par del eje horizontal encerrada en un óvalo, Colombia sólo en una de sus fincas, posee altas puntuaciones en las variables, reflejando una percepción positiva en Aroma, Sabor, Regusto, Acidez, Cuerpo, Balance y puntuación General. A diferencia de Etiopía en la parte superior cerca al eje vertical, una de sus fincas muestra una percepción media en la mayoría de los atributos sensoriales y el Salvador ubicado en la parte izquierda superior que tiene una puntuación relativamente baja en una de sus fincas. En la parte central, el conjunto mayoritario de las fincas posee altas puntuaciones en las variables reflejando una percepción positiva en Aroma, Sabor, Regusto, Acidez, Cuerpo, Balance y Puntuación General.

Cuadro II
EVALUACIÓN DE MODELOS

Nombre del Modelo	RMSE		MAE		R Squared	
	Entrenamiento	Prueba	Entrenamiento	Prueba	Entrenamiento	Prueba
Random Forest	0.3357	4.0333	0.1589	0.6594	0.9845	0.4892
GBM	0.3793	3.6760	0.2381	0.6186	0.9803	0.5757
SVR	0.7455	0.7803	0.2780	0.3459	0.9239	0.9808
Hybrid Model	0.4264	2.5915	0.1986	0.4805	0.9751	0.7891

Los resultados analizados de [3], se puede expresar como se muestra en el cuadro II, donde se visualiza una comparación de los cuatro modelos empleados y los resultados en el Error Cuadrático Medio (RMSE), Error Medio Absoluto (MAE) y R cuadrado, se evidencia que en el uso de SVR supera a: Random Forest, GBM e inclusive al modelo híbrido que al ser consistente tanto en conjuntos de datos de entrenamiento como a los de prueba, obtuvo de 0,7455 y 0,7803 en el resultado del RMSE para los datos de entrenamiento y de prueba respectivamente demostrando que SVR logró generalizar a los datos de prueba; es decir, el modelo SVR tiene la métrica de error RMSE más bajo que los otros modelos al enfrentarse a nuevos datos. El modelo híbrido muestra el segundo mejor rendimiento en las predicciones al generar como resultados: 2,5915(RMSE), 0,4805(MAE) y 0,7891(R al cuadrado) mientras que GBM y Random Forest obtuvieron

la tercera y cuarta posición en la predicción del valor de la calidad del café.

Cuadro III
CARACTERÍSTICAS SENSORIALES (PARTE 1)

	Aroma	Sabor	Sabor.Residual	Acidez	Cuerpo
0	4.169149	4.081212	3.904573	4.129179	3.863088
1	4.186828	4.102150	3.927104	4.148110	3.883823
2	4.153579	4.062771	3.884729	4.112505	3.844825
3	4.166920	4.078571	3.901731	4.126791	3.860473
4	4.092703	3.990672	3.807145	4.047317	3.773424
5	4.077327	3.972460	3.787548	4.030851	3.755389
6	4.157124	4.066969	3.889247	4.116301	3.849983
7	4.253943	4.181639	4.012641	4.219980	3.962543
8	4.227818	4.150697	3.979344	4.192003	3.931900
9	4.124254	4.028039	3.847355	4.081102	3.810430
10	4.116493	4.018847	3.837464	4.072792	3.801327
11	4.249141	4.175951	4.006520	4.214838	3.956910

Cuadro IV
CARACTERÍSTICAS SENSORIALES (PARTE 2)

	Balance	Uniformidad	Taza.Limpia	Dulzor	Overall
0	3.958924	4.205576	3.759331	4.053699	3.738016
1	3.983422	4.228165	3.781557	4.075748	3.761476
2	3.973747	4.185680	3.739755	4.034280	3.717353
3	3.955834	4.202726	3.756527	4.050918	3.735056
4	3.852988	4.107894	3.663220	3.958355	3.636569
5	3.831680	4.088247	3.643888	3.939178	3.616164
6	3.942259	4.190209	3.744212	4.038701	3.722057
7	4.076427	4.313923	3.865937	4.159454	3.850540
8	4.040223	4.280540	3.833091	4.126870	3.815870
9	3.896709	4.148209	3.702887	3.997705	3.678437
10	3.885954	4.138292	3.693129	3.988026	3.668138
11	4.069772	4.307787	3.859900	4.153465	3.844167

Uno de los resultados obtenidos donde el problema se enfoca en la regresión múltiple, es decir, lograr predecir los 10 atributos de calidad, a partir de los datos de entrada de la tesis[4]. Para ello se dejan 10 nodos en la capa de salida, uno por cada caracterizador de calidad. Una se completa el entrenamiento, los resultados de los cuadros III y IV, el MAE llega al valor de 12.55 % y una desviación del 5.1 %. Se aprecia generalmente la inclinación en la red trata de generalizar los resultados hacia la media de ellos, en los datos individuales se pueden apreciar diferencias tanto en las variables de una misma muestra, como en las muestras en general.

IV. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

IV-A. Configuración experimental

Para realizar este paso en la metodología de validación, se utilizará una partición de datos usando un 80 % para los datos de entrenamiento y 20 % para los datos de prueba, además se garantizará que los hiperparámetros seleccionados sean óptimos y se evitará el sobreajuste, aplicando la validación cruzada (Cross Validation) en el conjunto de entrenamiento. Adicionalmente, en el tratamiento de valores no disponibles (NA), se adjudica por mediana para las variables numéricas como la altitud y la moda para las variables categóricas. Para obtener los objetivos se analizaron los resultados de los siguientes modelos: Regresión Lineal, KNN, Random Forest, MLP y SVR. Para el desarrollo de estas técnicas, se utilizaron

varias funciones relevantes de scikit-learn que ejecutan los procesos de los modelos retornando los resultados de forma asertiva. Las funciones utilizadas fueron: SGDRegressor para regresión lineal, KNeighborsRegressor para KNN, RandomForestRegressor para random forest, MLPRegressor para redes neuronales y SVR para máquinas de vectores de soporte.

IV-B. Análisis de hiperparámetros

El resultado de cada modelo muestran diversos datos con cada uno de los hiperparámetros analizados en cada modelo, cabe aclarar que la sigla del encabezado 'IC' de los cuadros: V, VI, VII, VIII y IX representan el intervalo de confianza con sus respectivos porcentajes.

Analizando los resultados del cuadro V, se evidencia que la tasas de aprendizaje óptimas son de: 0.001 y 0.010; dado que la tendencia del R^2 se acerca más a 1 confirmando un rendimiento muy alto. Adicionalmente la desviación estándar es muy pequeña haciendo que el intervalo de confianza sea más estable.

Cuadro V
VALIDACIÓN CRUZADA DE REGRESIÓN LINEAL (SGD)

T. aprendizaje (η)	R^2 Media	Desviación (σ)	IC (95 %)
0.001	9.9004e-01	6.1218e-03	[0.9778, 1.0023]
0.010	9.8444e-01	1.0171e-02	[0.9641, 1.0048]
0.100	-9.1366e+22	8.0580e+22	$[-2,53 \times 10^{23}, 6,98 \times 10^{22}]$
0.500	-5.0913e+23	2.8727e+23	$[-1,08 \times 10^{24}, 6,54 \times 10^{22}]$

Los resultados del cuadro VI, se nota una caída en R^2 cuando los vecinos incrementan de 3 a 21; eso quiere decir que toma las decisiones muy cercanas en base únicamente con los cafés más parecidos, logrando mayor precisión cuando el valor es pequeño, a comparación cuando $k = 21$ que realiza un underfitting o subajuste al promediar varios tipos de cafés de alta calidad con otros más comerciales.

Cuadro VI
VALIDACIÓN CRUZADA DE KNN

Vecinos (k)	R^2 Media	Desviación (σ)	IC (95 %)
3	0.846345	0.178587	[0.4892, 1.2035]
5	0.828003	0.188635	[0.4507, 1.2053]
11	0.797706	0.204249	[0.3892, 1.2062]
21	0.757903	0.203701	[0.3505, 1.1653]

El análisis del cuadro VII, la profundidad mínima de 3 no abarca lo suficiente para el aprendizaje, comparado con una de 10 ó 20 con R^2 de 0,8480 y 0,8499 respectivamente evidenciando que a partir de la profundidad 10 ya obtuvo casi toda la información útil. Se puede afirmar que el más óptimo es 20 en la profundidad, no obstante, el uso de 10 puede ser otra alternativa a razón del ahorro de cómputo y la diferencia de R^2 no es muy significativa.

Para entender la información del cuadro VIII, si el valor del hiperparámetro de regularización es muy bajo, tiende a priorizar la simplicidad del margen plano por encima de los errores, eso quiere decir que con un C bajo (0,1), el modelo no

Cuadro VII
VALIDACIÓN CRUZADA DE RANDOM FOREST

Profundidad (max_depth)	R^2 Media	Desviación (σ)	IC (95 %)
3	0.757953	0.159853	[0.4382, 1.0777]
5	0.823295	0.178954	[0.4654, 1.1812]
10	0.848008	0.188080	[0.4718, 1.2242]
20	0.849953	0.188704	[0.4725, 1.2274]

es el mejor con $R^2 = 0,47013$. Sin embargo, al incrementar C hasta 100, el ajuste sube de forma sostenida hasta 0.7635.

Cuadro VIII
VALIDACIÓN CRUZADA DE SVR

Regularización (C)	R^2 Media	Desviación (σ)	IC (95 %)
0.1	0.470130	0.182291	[0.1055, 0.8347]
1.0	0.648813	0.235073	[0.1787, 1.1190]
10.0	0.740947	0.253499	[0.2339, 1.2479]
100.0	0.763524	0.262998	[0.2375, 1.2895]

Finalmente, la información del cuadro IX, al usar dos capas con 50 y 25 neuronas respectivas en cada capa, se logra un aprendizaje estable con el punto óptimo de la red equivale a $R^2 = 0,7670$, igualmente la desviación estándar es la más baja $\sigma = 0,15$, lo que hace que los intervalos de confianza sean más seguros en éste modelo en comparación de una capa con 10 neuronas que puede generar un subajuste o el de tres capas con 100, 50 y 25 neuronas en cada capa respectiva que genera un sobreajuste; al añadir una tercera capa y elevar el número de neuronas tendrá muchos parámetros libres adicionales o pesos y sesgos.

Cuadro IX
VALIDACIÓN CRUZADA DE PERCEPTRÓN MULTICAPA (MLP)

Arquitectura (Capas)	R^2 Media	Desviación (σ)	IC (95 %)
(10,)	-7.240906	2.420140	[-12.0812, -2.4006]
(50, 25)	0.767070	0.150081	[0.4669, 1.0672]
(100, 50, 25)	0.366740	0.402889	[-0.4390, 1.1725]

IV-C. Métricas de desempeño

Simplificando los datos de de los cuadros: V, VI, VII, VIII y IX, y ajustando los mejores hiperparámetros, se enumeran en orden descendente el desempeño de mejor a deficiente resumidos en el cuadro X. Por conveniencia, en el cuadro X, se haran referencias a los encabezados: 'Train', 'Test' y 'seg' como: entrenamiento, pruebas y segundos respectivamente.

La regresión lineal se lleva el mérito con un tiempo de 0.007 segundos con un rendimiento aproximado del 98,9 % en el entrenamiento y un 98,2 % en las pruebas. Por otra parte, MLP a pesar en el entrenamiento obtiene un aproximado al 94,9 %, en las pruebas se desploma a un 62,6 %

En la figura 2, se puede apreciar gráficamente los resultados evaluados del desempeño de los modelos del cuadro X; evidentemente la longitud del MSE de la regresión lineal es la más corta seguido de RMSE, de esta forma se demuestra

Cuadro X
TABLA DE DESEMPEÑO DE LOS MODELOS

Modelo	MSE		RMSE		R^2		Tiempo (seg)
	Train	Test	Train	Test	Train	Test	
1. Reg. Lineal (SGD)	0.1508	0.1089	0.3884	0.3300	0.9891	0.9826	0.007
2. KNN	2.9086	0.3648	1.7055	0.6040	0.7905	0.9417	0.087
3. Random Forest	0.7307	0.4021	0.8548	0.6341	0.9474	0.9357	2.089
4. SVR	7.1288	0.7088	2.6700	0.8419	0.4864	0.8866	0.421
5. MLP (Perceptrón)	0.7067	2.3381	0.8407	1.5291	0.9491	0.6260	5.380

la eficiencia de este modelo en comparación de los demás evaluados.




Figura 2. Comparativa de error de los modelos

V. REDUCCIÓN DE DIMENSIÓN

V-A. Análisis individual de las variables

En el momento de realizar el análisis individual de las variables, la varianza que representan cada una de ellas muestra la certeza que la variable 'Humedad', es una clara característica que se puede eliminar sin problema, la causa razonable según los resultados del cuadro XI, no afectaría dado al tener un puntaje de 0.002 que es muy cercano a cero, el único impacto sólo reflejaría la eliminación del ruido sin alterar en absoluto a R^2 .

Cuadro XI
ANÁLISIS DE VARIANZA INDIVIDUAL

Característica	Varianza (σ^2)
Humedad	0.00228
Cuerpo	0.14325
Acidez	0.15631
Aroma	0.15682
Balance	0.17317
Sabor	0.17473
Sabor.Residual	0.17705
Dulzura	0.31585
Uniformidad	0.33484
Taza.Limpia	0.64255

Adicionalmente, existen otras características que pueden ser candidatas secundarias a ser eliminadas: 'Dulzura' y 'Taza.Limpia'; estas características según la figura 3, en el mapa

de calor se ubican por las zonas frías, además tiene baja varianza. Aún así, puede mantener el objetivo y no perdería el poder predictivo si se encuentran asuertes.




Figura 3. Matriz Correlación de Características

V-B. Extracción de características lineal

Previamente en la figura2 se demostraron los mejores modelos que se pueden utilizar por el desempeño en las pruebas realizadas son: Regresión lineal y KNN, los cuales se consideraron óptimos para realizar el método PCA. Los resultados al evaluar se muestran en el cuadro XII, se visualiza una reducción del 30 % de datos redundantes en el espacio de características, es decir, este 30 % actuaba como ruido estructural en los modelos y al eliminarlo funciona de forma más óptima y matemáticamente con más precisión. Si se comparan los resultados de R^2 entre el cuadro X con el cuadro XII en el test, sube con regresión lineal de 0.9826 a 0.9919 y con KNN de 0.9417 a 0.9469.

Cuadro XII
MODELOS DE PREDICCIÓN CON REDUCCIÓN DE DIMENSIÓN LINEAL (PCA)

Modelo PCA	Var. Orig.	Comp. PCA	Reducc. (%)	Test RMSE	Test R^2	Tiempo (seg)
Reg. lin.	10	7	30 %	0.2242	0.9919	0.0216
KNN	10	7	30 %	0.5757	0.9469	0.0434

V-C. Extracción de características no lineal

Analizando los resultados en en base a los mejores modelos con mejor desempeño demostrados en la figura 2, se nota la incompatibilidad entre la regresión lineal y el espacio embebido del método UMAP; dicho de otra forma el resultado negativo de $R^2 = -0,0572$ del cuadro XIII, equivale a decir

que el modelo es peor que tirar una moneda al aire o asignar el promedio a todas las predicciones resultando en un desempeño inferior al de un modelo trivial basado en la media.

En contraste, pese a perder el 70 % de las variables originales en los resultados de KNN, se nota cierta resiliencia al mantener un desempeño sólido del 82.46 % y un puntaje del RMSE de 1.047 a diferencia de la regresión lineal que obtuvo como resultado un 2.571 puntos de error.

Cuadro XIII
MODELOS DE PREDICCIÓN CON REDUCCIÓN DE DIMENSIÓN NO LINEAL (UMAP)

Modelo UMAP	Var. Orig.	Comp. UMAP	Reducc. (%)	Test RMSE	Test R^2	Tiempo (seg)
Reg. Lin.	10	3	70.0 %	2.5708	-0.0572	0.0132
KNN	10	3	70.0 %	1.0472	0.8246	0.0018

VI. CONCLUSIONES

La evaluación de los modelos implementados que han sido objeto de estudio de los resultados globales de los cuadros II y X, se notan unas discrepancias en algunos de los modelos; si se observa el modelo Random Forest del cuadro II presenta un sobreajuste de R^2 de 0.9845 en el entrenamiento a un deficiente 0.4892 en prueba. En contraste, el Random Forest del cuadro X, alcanzó un R^2 de prueba de 0.9357. Esta mejora se atribuye a la restricción estratégica de la profundidad máxima (max_depth=10), la cual permite controlar la varianza del ensamble.

Continuando el análisis, para SVR reporta un mejor desempeño en el cuadro II con un R^2 en prueba de 0.9808. Sin embargo, en el cuadro X, el SVR obtuvo un R^2 de 0.8866, demostrando que el escalado estándar aplicado y los hiperparámetros por defecto ($C=1.0$, $\gamma=\text{'scale'}$) requirieron una optimización más agresiva en la validación cruzada en el cuadro VIII, donde es clara evidencia que valores más altos de penalización ($C=100.0$) eran necesarios para aproximar el comportamiento lineal del objetivo.

El mejor modelo, la Regresión Lineal, con un R^2 de 0.9826, RMSE de 0.3300, superó al mejor modelo híbrido del cuadro II con un R^2 de 0.7891. Sin lugar a duda éste modelo, a parte de competir con los demás modelos, es el que tiene las mejores métricas en el desarrollo de los resultados.

Para finalizar, del contraste de los paradigmas lineal PCA y no lineal UMAP, demuestra que la reducción de dimensionalidad lineal mediante PCA manifiesta ser la técnica óptima para este problema, además que no solo disminuyó la complejidad del modelo en un 30 %, también refinó los datos eliminando variables redundantes de baja varianza, conllevando al incremento en la precisión predictiva general. En contraparte, si bien UMAP permite una compresión drástica del espacio de características equivalente al 70 %, está estrictamente condicionado al emparejamiento con regresores no paramétricos basados en vecindad geométrica (KNN). Implicando en estar

no recomendado para uso en conjunto con aproximaciones paramétricas lineales.

REFERENCIAS

- [1] A. F. Ochoa-Muñoz, J. A. Peña-Torres, C. E. García-Bermúdez, K. F. Mosquera-Muñoz y J. Mesa-Diez, "On characterization of sensory data in presence of missing values: The case of sensory coffee quality assessment", *Ingeniare. Revista chilena de ingeniería*, vol. 30, no. 3, pp. 564–573, 2022. [En línea]. Disponible en: https://revistas.uta.cl/pdf/2940/vol30_n3_art12.pdf
- [2] V. Espinoza Romano, V. R. Figueroa Camacho y S. A. Aldunate Flores, "Análisis de atributos sensoriales que influyen en la percepción de calidad del café mediante la técnica multivariada de componentes principales," *Acta Nova*, vol. 11, no. 4, Cochabamba, Bolivia, Nov. 2024. [En línea]. Disponible en: <http://www.scielo.org.bo/pdf/ran/v11n4/1683-0789-ran-11-04-353.pdf>
- [3] M. K. Melewwwe Thantrige, "Utilizing Machine Learning Techniques for Excellent Coffee Prediction," Tesis de maestría, MSc Research Project, School of Computing, National College of Ireland, 2024. [En línea]. Disponible en: <https://norma.ncirl.ie/id/eprint/7570>
- [4] J. A. Suárez Peña, "Modelo de aprendizaje automático para la predicción de la calidad del café," Tesis de maestría, Universidad Distrital Francisco José de Caldas, Bogotá, Colombia, 2024. [En línea]. Disponible en: <http://hdl.handle.net/11349/23560>